



HW 1

① Seja $Y \sim \text{Exp}(\lambda)$ e $a > 0$. Consideraremos a variável depois de restringir seu repte. Oe seja, $X = Y | Y \geq a$ e q. X tem mesma lei de Y com a condição de estar em $[a, \infty)$. Calcule $F_x(x)$, a função acumulada de X , e $F_x^{-1}(u)$ a função quantil de X . Descreva um algoritmo para simular X de $\mathcal{U}([0, 1])$.

Temos que $f_Y(y) = \lambda e^{-\lambda y}$.

Daí a CDF de X é

$$F_x(x) = P(X \leq x) = P(Y \leq x | Y \geq a)$$

$$= \frac{P(a \leq Y \leq x)}{P(Y \geq a)}$$

$$\cdot P(a \leq Y \leq x) = \int_a^x \lambda e^{-\lambda y} dy$$

$$\cdot P(Y \geq a) = \int_a^\infty \lambda e^{-\lambda y} dy = e^{-\lambda a}$$

$$\int_a^x \lambda e^{-\lambda y} dy = \left[-e^{-\lambda y} \right]_a^x = e^{-\lambda a} - e^{-\lambda x}$$

Então

$$F_x(x) = \frac{e^{-\lambda a} - e^{-\lambda x}}{e^{-\lambda a}} = 1 - e^{\lambda(x-a)}, \quad x \geq a$$

Para a função quantil $F_x^{-1}(u)$, deve satisfazer $F_x(F_x^{-1}(u)) = u$. Como $F_x(x) = 1 - e^{\lambda(x-a)}$, resolvendo para x

$$u = 1 - e^{\lambda(x-a)} \Rightarrow e^{\lambda(x-a)} = 1 - u$$

$$\Rightarrow x = a - \frac{\ln(1-u)}{\lambda} := F_x^{-1}(u)$$

Para simular X a partir de uma Uniforme $[0, 1]$, basta Computar $X = F_x^{-1}(U) = a - \frac{\ln(1-U)}{\lambda}$, onde $U \sim \mathcal{U}([0, 1])$.

tilibra

② Sejam a e b dados com $a < b$. Mostre que podemos simular $X = Y | a \leq Y \leq b$ de $U \sim U_{[0,1]}$, usando

$$X = F_Y^{-1}(F_Y(a)(1-U) + F_Y(b)U).$$

e.g. mostre que X tomá é dado pela fórmula acima, entre $P(X \leq x) = P(Y \leq x | a \leq Y \leq b)$. Aplique a fórmula para o problema anterior.

$F_X(x) = P(X \leq x)$ é 0 para de $a \leq x \leq b$. Neste caso,

$$P(X \leq x) = P(F_Y^{-1}(F_Y(a)(1-U) + F_Y(b)U) \leq x)$$

$$= P(F_Y(a)(1-U) + F_Y(b)U \leq F_Y(x))$$

$$= P\left(U \leq \frac{F_Y(x) - F_Y(a)}{F_Y(b) - F_Y(a)}\right) = \frac{F_Y(x) - F_Y(a)}{F_Y(b) - F_Y(a)}$$

Para a exponencial condicional, para $F_Y(v) = 1 - \exp(-\lambda v)$, e $b = \infty$ então $F_Y(b) = 1$

$$F_Y(a)(1-U) + F_Y(b)U = (1 - \exp(-\lambda a))(1-U) + U$$

$$\Rightarrow F_Y^{-1}(v) = -\lambda^{-1} \log(1-v)$$

$$\Rightarrow X = -\lambda^{-1} \log(1 - (1 - \exp(-\lambda a))(1-U) + U)$$

$$\Leftrightarrow = -\lambda^{-1} \log(\exp(-\lambda a)(1-U))$$

$$= a - \lambda^{-1} \log(1-U).$$

③ Aqui é um algoritmo simples para simular $X = Y | Y \geq a$ para $Y \sim \text{Exp}(\lambda)$:

(a) Seja $Y \sim \text{Exp}(\lambda)$. Simula $Y \geq$

(b) Se $Y \geq a$ para e retorne $X = y$, e caso contrário, vai para o passo(a).

Mostre que este é um algoritmo de eficácia, excetuando as chances de�as e alvo como π e g , dem como o limite $M = \max \pi(x)/g(x)$. Calcule o número esperado de tentativas para a primeira aci-
ção. Por que a inversão é preferida para $a \gg \lambda$?

As densidades proposta e alvo são

$$g(y) = \lambda \exp(-\lambda y), \quad y \geq 0$$

$$\pi(x) = \lambda \exp(-\lambda(x-a)) \mathbb{I}(x \geq a).$$

O limite $M = \max \pi(x)/g(x)$ é $M = \exp(\lambda a)$ e então a prob-
abilidade de acertos do algoritmo de eficácia é

$$\frac{\pi(y)}{M g(y)} = \begin{cases} 1 & y \geq a \\ 0 & y < a \end{cases}$$

Como acertamos grande $y \geq a$ e erramos caso contrário.
Este algoritmo corresponde ao descrito acima. O número de ten-
tativas N é distribuído geometricamente com probabilidade pa-
ra onde p é a probabilidade de acertar $y \geq a$, que é $p = \exp(-\lambda a)$.
O valor esperado é $EN = 1/p = \exp(\lambda a)$. Se $a \lambda \gg 1$, entao
 EN é grande. A inversão fornece uma amortia com uma analis-
e de função única.

④ Considere o seguinte algoritmo de rejeição "queijo" para amostrar de uma distribuição $\tilde{\pi}(x) = \tilde{\pi}(x)/Z_g$ num espaço de estado X tal que

$$l(x) \leq \tilde{\pi}(x) \leq M\tilde{g}(x)$$

onde l é uma função, $M > 0$ e $g(x) = \tilde{g}(x)/Z_g$ é a densidade de uma distribuição que podemos amostrar. O algoritmo segue como:

- (a) Amostra independentemente $X \sim g$, $U \sim \text{Unif}[0,1]$.
- (b) Aceita X se $U \leq l(x)/(M\tilde{g}(x))$.
- (c) Se X não é aceito ~~não~~^{no} para (b), amostra independentemente $V \sim \text{Unif}[0,1]$ e aceite X se

$$V \leq \frac{\tilde{\pi}(x) - l(x)}{M\tilde{g}(x) - l(x)}$$

Mostre que a probabilidade de aceitação um $X=x$ proposta em cada passo de (b) ou (c) é

$$\frac{\tilde{\pi}(x)}{M\tilde{g}(x)}$$

Temos que $P(X=x \text{ reaceito}) =$

$$P(X=x \text{ reaceito em (b)}) + P(X=x \text{ reaceito em (c)})$$

onde

$$P(X=x \text{ reaceito em (b)}) = \int_0^1 \mathbb{I}(u \leq \frac{l(x)}{M\tilde{g}(x)}) du$$

$$= \frac{l(x)}{M\tilde{g}(x)}$$



e

$$\begin{aligned} P(X=x \text{ rea auto em } c) &= \int_0^1 \int_0^1 \mathbb{I}(u > \frac{h(x)}{M\tilde{g}(x)}) \mathbb{I}(v < \frac{\tilde{\pi}(x) - h(x)}{M\tilde{g}(x) - h(x)}) du dv \\ &= \left(\frac{\tilde{\pi}(x) - h(x)}{M\tilde{g}(x) - h(x)} \right) \left(1 - \frac{h(x)}{M\tilde{g}(x)} \right) \\ &= \frac{\tilde{\pi}(x) - h(x)}{M\tilde{g}(x) - h(x)} - \frac{h(x)(\tilde{\pi}(x) - h(x))}{M\tilde{g}(x)(M\tilde{g}(x) - h(x))} \\ &= \frac{M\tilde{g}(x)\tilde{\pi}(x) - M\tilde{g}(x)h(x) - h(x)\tilde{\pi}(x) + h^2(x)}{M\tilde{g}(x)(M\tilde{g}(x) - h(x))} \\ &= \frac{(M\tilde{g}(x) - h(x))(\tilde{\pi}(x) - h(x))}{M\tilde{g}(x)(M\tilde{g}(x) - h(x))} \\ &= \frac{\tilde{\pi}(x) - h(x)}{M\tilde{g}(x)} \end{aligned}$$

O que completa a prova

5) Deduya da questão anterior que a distribuição das amostras acima pelo algoritmo é π .

$$P(X \in A | X \text{ foi acito}) = \frac{P(X \in A, A \text{ foi acito})}{P(A \text{ foi acito})}$$

$$\begin{aligned} &= \frac{\int_A \frac{\pi(x)}{Mg(x)} g(x) dx}{\int_X \frac{\pi(x)}{Mg(x)} g(x) dx} \\ &= \frac{\int_A \frac{\pi(x)}{Mg(x)} g(x) dx}{\int_X \frac{\pi(x)}{Mg(x)} g(x) dx} \\ &= \frac{\int_A \pi(x) dx}{\int_X \pi(x) dx} \end{aligned}$$

$$\text{Pois } Z_\pi = \int_X \pi(x) dx \rightarrow = \int_A \pi(x) dx$$

⑥ Da questão ④ mostra que a probabilidade de que a etapa (c) tenha que ser executada é

$$1 - \frac{\int_x h(x) dx}{M Z_g}$$

$$\begin{aligned} P(X \text{ ser apitado no passo (b)}) &= \int_x^1 \int_0^1 \Pi(u) \frac{g(x)}{M g(x)} q(u) du dx \\ &= \int_x^1 \left(1 - \frac{h(x)}{M Z_g}\right) q(x) dx \\ &= \int_x^1 q(x) - \frac{h(x)}{M Z_g} dx \\ &= \underbrace{\int q(x) dx}_{1} - \frac{\int_x^1 h(x) dx}{M Z_g} \\ &= 1 - \frac{\int_x^1 h(x) dx}{M Z_g}. \end{aligned}$$



4) Da questão 4). Seja $\tilde{\pi}(x) = \exp(-x^2/2)$ e $\tilde{q}(x) = \exp(-|x|)$.
Quando a pto que

$$\tilde{\pi}(x) \geq 1 - \frac{x^2}{2}, \forall x \in \mathbb{R},$$

como voce poderia usar o algoritmo para amostra $\pi(x)$. Qual é a probabilidade de não ter que avaliar $\tilde{\pi}(x)$? Por que seria benéfico usar este algoritmo em vez do procedimento padrão de amostragem por rejeição?

Pela sugestão

$$Q(x) = \begin{cases} 1 - \frac{x^2}{2} & \text{se } |x| \leq \sqrt{2} \\ 0 & \text{caso contrário} \end{cases}$$

Temos

$$\sup_{x \in \mathbb{R}} \frac{\tilde{\pi}(x)}{Q(x)} = \sup_{x \in \mathbb{R}} \exp\left(-x^2/2 + |x|\right) = \sqrt{e} \approx 1.78$$

$$\text{Com probabilidade } \int_{-\infty}^{\infty} Q(x) dx / (M Z_f) = \frac{2\sqrt{2}(1-2/6)}{\sqrt{e} \times 2} = \frac{2}{3}\sqrt{\frac{2}{e}} \approx 0.57$$

não temos que avaliar $\tilde{\pi}(x)$

Como $Q(x)$ tem ~~significativa~~ computação significativamente mais barata do que $\exp(-x^2/2)$, podemos esperar ganhos.

⑧ Considere o seguinte algoritmo conhecido como Marsaglia's polar method.

(a) Gera independentemente $U_1, U_2 \sim \text{Unif}[-1, 1]$ até $Y = U_1 U_2 \leq 1$.

(b) Defina

$$Z = \sqrt{-2 \log(Y)}$$

e retorne

$$X_1 = Z \frac{U_1}{\sqrt{Y}}, \quad X_2 = Z \frac{U_2}{\sqrt{Y}}.$$

Defina $\vartheta = \arctan(U_2/U_1)$. Mostre que a distribuição conjunta de Y e ϑ tem densidade

$$f_{Y,\vartheta}(y, \theta) = \mathbb{I}_{[0,1]}(y) \frac{\mathbb{I}_{[0,2\pi]}(\theta)}{2\pi}.$$

Podemos interpretar o passo (a) como um algoritmo de rejeição para amostragem de uma distribuição uniforme na esfera unitária D ou seja

$$D := \{(U_1, U_2) \in \mathbb{R}^2 : U_1^2 + U_2^2 \leq 1\}.$$

O mapeamento $(Y, \theta) = T(u_1, u_2) = (u_1^2 + u_2^2, \arctan(u_2/u_1))$ é bimórfico de D em $(0, 1) \times (0, 2\pi)$ com inversa $(u_1, u_2) = T^{-1}(Y, \theta) = (\sqrt{Y} \cos \theta, \sqrt{Y} \sin \theta)$. O Jacobiano de T^{-1} é

$$\left| \det \begin{pmatrix} \frac{\partial u_1}{\partial Y} & \frac{\partial u_1}{\partial \theta} \\ \frac{\partial u_2}{\partial Y} & \frac{\partial u_2}{\partial \theta} \end{pmatrix} \right| = \left| \det \begin{pmatrix} \frac{\cos \theta}{2\sqrt{Y}} & -\sqrt{Y} \sin \theta \\ \frac{\sin \theta}{2\sqrt{Y}} & \sqrt{Y} \cos \theta \end{pmatrix} \right| = \frac{1}{2}$$

então $f_{Y,\vartheta}(y, \theta) = f_{u_1, u_2}(T^{-1}(Y, \theta)) \cdot \frac{1}{2} = f_{u_1}(\sqrt{Y} \cos \theta, \sqrt{Y} \sin \theta) \cdot \frac{1}{2}$

$$= \mathbb{I}_{[0,1]}(y) \cdot \frac{\mathbb{I}_{[0,2\pi]}(\theta)}{2\pi}.$$



⑨ Da questão anterior note que X_1 e X_2 são independentes com distribuição normal padrão.

Pela questão anterior $Y \sim U[0,1]$ e $\vartheta \sim U[0,2\pi]$ independentes. Daí $Z^2 = -2\log Y \sim \text{Exp}(1/2)$ e $\vartheta \sim U[0,2\pi]$ são independentes. Portanto,

$$X_1 = Z \cos \vartheta, X_2 = Z \sin \vartheta$$

são independentes de normal padrão, pelo Box-Muller algoritmo.



⑩ Qual os potenciais benefícios de uma abordagem usando Box-Muller algoritmo?

Análises de funções ~~trigonométricas~~ tendenciarão a ser auto-
res, o algoritmo ignora essas ~~analogias~~.