

HW 2

① Seja $\tilde{f}(x) = \tilde{f}(x)/2\pi$ alguma função de densidade em \mathbb{R} .
Prove que se (U, V) é uniformemente distribuído em $G = \{(u, v); 0 \leq u \leq \sqrt{\tilde{f}(v)}\}$,
então V/U é distribuído de acordo com $\tilde{f}_x(x)$, ~~é uma função de densidade~~.

$$f_{U,V}(u,v) = \frac{1}{\text{Area}(G)}$$

Poderemos nos concentrar em $X = V/U$ e $U = u$. Daí $V = Xu$.
O Jacobiano para a transformação

$$J = \begin{vmatrix} 1 & 0 \\ x & u \end{vmatrix} = u$$

Daí, a densidade conjunta de x e u é

$$f_{U,X}(u,x) = f_{U,V}(u,ux) \cdot |u|$$

$$\text{Então } f_x(x) = \int_0^{\sqrt{\tilde{f}(x)}} f_{U,V}(u,ux) u du$$
$$= \frac{1}{\text{Area}(G)} \int_0^{\sqrt{\tilde{f}(x)}} u du = \frac{1}{\text{Area}(G)} \frac{\tilde{f}(x)}{2}.$$

Evaluating the $\text{Area}(G)$:

$$\text{Area}(G) = \iint_{\substack{0 \leq u \leq \sqrt{\tilde{f}(v)} \\ -\infty \leq v \leq \infty}} 1 du dv$$
$$= \int_{-\infty}^{\infty} \int_0^{\sqrt{\tilde{f}(x)}} u du dx = \int_{-\infty}^{\infty} \frac{\tilde{f}(x)}{2} dx = \frac{2\tilde{f}(x)}{2}$$

Então,

$$f_x(x) = \frac{1}{\text{Area}(G)} \frac{\tilde{f}(x)}{2} = \frac{2}{2\pi} \frac{\tilde{f}(x)}{2} = \frac{\tilde{f}(x)}{2\pi} = \tilde{f}(x).$$

② A partir do problema anterior. Mostre que se $\sup_x \sqrt{f(x)} < \infty$ e $\sup_x \sqrt{f(x)}.|x| < \infty$, então $G \subseteq \mathbb{R}$ onde

$$R = [0, \sup_x \sqrt{f(x)}] \times [\inf_x x \sqrt{f(x)}, \sup_x x \sqrt{f(x)}]$$

Significa uma maneira de amostrar uniformemente de G .

Provar que $G \subseteq R$ é equivalente a provar que

$$\forall v \in [0, \sup_x \sqrt{f(x)}] \quad \exists u \in [\inf_x x \sqrt{f(x)}, \sup_x x \sqrt{f(x)}]$$

- Por definição $\forall v \in U \ni T_q, v \geq 0$.
- Também por definição $\forall v \in U, u \leq \sqrt{f(v)}$, $\forall v \in R$

$$\forall v \in U, u \leq \sup_v \sqrt{f(v)} = \sup_x \sqrt{f(x)}$$

$$\sup_u u \leq \sup_x x \sqrt{f(x)}$$

- Desde que $v = ux$, temos que

$$|v| = |ux| \leq |u||x| \leq \sup_x x \sqrt{f(x)} \cdot |x|$$

Daí,

$$\sup_x |v| \leq \sup_x |x| \sqrt{f(x)}$$

- Analogamente,

$$\inf_x |v| \geq \inf_x |x| \sqrt{f(x)}.$$

Para amostrar uniformemente:



1. A morte (u, v) uniformemente no triângulo R :

- $u \sim U_{[0, \sup \sqrt{f(x)}]}$
- $v \sim U_{[x]} \left[\inf_x \sqrt{f(x)}, \sup_x \sqrt{f(x)} \right]$.

2. A morte se

$$u \in \sqrt{f}(V_u)$$

Se não, repetimos a morte e voltamos ao passo 1.

A morte $\neq u \in \sqrt{f}$.



③ Seja $\tilde{\pi}(x) = \exp(-x^2/2)$. Usando os resultados das questões anteriores (1 e 2), proponha um método para amostrar $\tilde{\pi}(x)$.

Para o resultado da questão ②, temos que

$$\sup_x \sqrt{\tilde{\pi}(x)} = \sqrt{\tilde{\pi}(0)} = 1$$

$$\inf_x x \sqrt{\tilde{\pi}(x)} = \cancel{0} < 0$$

$$\sup_x x \sqrt{\tilde{\pi}(x)} = (\sqrt{2}) \sqrt{\exp(-(1/2)^2/2)} = (\sqrt{2}) \sqrt{\exp(-1)} = \sqrt{2} \exp(-\frac{1}{2})$$

Daí, $R = [0, 1] \times [0, \sqrt{2} \exp(-\frac{1}{2})]$.

Basta:

① Amostrar (U, V) uniformemente em R :

$$u \sim \text{Unif}[0, 1]$$

$$v \sim \text{Unif}[0, \sqrt{2} \exp(-\frac{1}{2})]$$

② Verificar se

$$u \leq \sqrt{\tilde{\pi}(v_u)}$$

Se não, repetir ①.

Assim $\frac{V}{u} \sim \tilde{\pi}$

④ Considere 2 densidades de probabilidade π , g em X tal que $\pi(x) > 0 \Rightarrow g(x) > 0$ e assuma que podemos amostrar g facilmente. Sempre que $\pi(x)/g(x) \leq M$ os para qualquer $x \in X$, é possível usar rejection sampling para amostrar π . Quando M é desconhecido ou quando esta condição não é satisfeita, podem usar importance sampling para aproximar as expectativas com respeito a π . No entanto, pode ser que a maioria das amostras de g tenham pesos de importâncias pequenos.

O rejection control é um método que combina rejection e importance. Ele se baseia em um valor limite arbitrário $c > 0$. Introduzimos a notação $w(x) = \pi(x)/g(x)$ e

$$Z_c = \int_X \min\{1, w(x)/c\} g(x) dx.$$

O método de rejection control procede da forma que

- (a) Gerar independentemente $X \sim g$, $U \sim U[0,1]$ até $U \leq \min\{1, \frac{w(x)}{c}\}$.
- (b) Retorne X .

Dá a expressão para densidade de probabilidade de $g^*(x)$, as amostras acima.

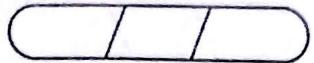
Temos $P(X \in A, X \text{ reacito}) = \iint_A \min\left\{1, \frac{w(x)}{c}\right\} g(x) du dx$

$$= \int_A \min\left\{1, \frac{w(x)}{c}\right\} g(x) dx$$

então

$$g^*(x) = \min\left\{1, \frac{w(x)}{c}\right\} g(x).$$

$$Z_c$$



⑤ Do problema anterior, prove que

$$\mathbb{E}_{\pi^*} [w^*(x)]^2 = Z_c \mathbb{E}_q (\max \{w(x), c\} w(x))$$

onde $w^*(x) = \pi(x) / q^*(x)$.

Temos que

$$\begin{aligned} \frac{\pi(x)}{q^*(x)} &= Z_c \frac{\pi(x)}{\min \{1, w(x)/c\} q(x)} \\ &= Z_c w(x) \cdot \frac{1}{\min \left\{1, \frac{w(x)}{c}\right\}} \\ &= Z_c \cdot \max \{w(x), c\}. \end{aligned}$$

Daí,

$$\begin{aligned} \mathbb{E}_{\pi^*} [w^*(x)]^2 &= \int_x \frac{\pi^2(x)}{q^{*2}(x)} \cdot q^*(x) dx \\ &= \int_x \frac{\pi^2(x)}{q^*(x)} dx \\ &= Z_c \int_x \max \{w(x), c\} \pi(x) dx \\ &= Z_c \int_x \max \{w(x), c\} w(x) \cdot q(x) dx \\ &= Z_c \mathbb{E}_q (\max \{w(x), c\} w(x)). \end{aligned}$$

⑥ Considerando as questões ④ e ⑤. Estabeleça que

$$\mathbb{E}_g(\min\{w(x), c\}) \mathbb{E}_g(\max\{w(x), c\} w(x)) \leq$$

$$\leq \mathbb{E}_g(\min\{w(x), c\} \max\{w(x), c\} w(x))$$

$$\text{Sendo } h(w, w_2) = [\min(w, c) - \min(w_2, c)] [w, \max(w, c) - w_2, \max(w_2, c)]$$

Poderemos distinguir 3 casos

(i) $\min(w, w_2) > c$, então $h(w, w_2) = 0$.

(ii) $c > \max(w, w_2)$, então $h(w, w_2) = (\underline{\underline{c}})(\underline{\underline{c}}) c (w_1 - w_2)^2 \geq 0$

(iii) c está entre w e w_2 , sem perda de generalidade, vamos assumir $w_1 \leq w_2$, daí

$$h(w_1, w_2) = (c - w_1)(w_2^2 - cw_1) \geq 0.$$

Portanto, temos

$$\iint h(w(x), w(y)) g(x) g(y) dx dy$$

$$= 2 \int \min(w(x), c) w(x) \max(w(x), c) g(x) dx$$

$$- 2 \left(\int \min(w(x), c) g(x) dx \right) \left(\int w(x) \max(w(x), c) g(x) dx \right)$$

$$\geq 0$$

Daí,

$$\mathbb{E}_g(\min(w(x), c)) \mathbb{E}_g(\max(w(x), c) w(x))$$

$$\leq \mathbb{E}_g(\min(w(x), c) \max(w(x), c) w(x)).$$

⑦ Deduza das questões ④, ⑤ e ⑥ que

$$\text{Var}_{\mathbb{P}^*}(w^*(x)) \leq \text{Var}_{\mathbb{P}}(w(x))$$

Uma vez que $\mathbb{E}_{\mathbb{P}^*}(w^*(x)) = \mathbb{E}_{\mathbb{P}}(w(x)) = 1$, é equivalente a provar que

$$\mathbb{E}_{\mathbb{P}^*}([w^*(x)]^2) \leq \mathbb{E}_{\mathbb{P}}([w(x)]^2).$$

Para isso,

$$\mathbb{E}_{\mathbb{P}^*}([w^*(x)]^2) \stackrel{\textcircled{1}}{=} \mathbb{E}_{\mathbb{P}}(\max(w(x), c)w(x))$$

$$= c^2 \mathbb{E}_{\mathbb{P}}(\min(w(x), c)) \mathbb{E}_{\mathbb{P}}(\max(w(x), c)w(x))$$

$$\leq c^2 \mathbb{E}_{\mathbb{P}}(\min(w(x), c)\max(w(x), c)w(x))$$

$$= \mathbb{E}_{\mathbb{P}}([w(x)]^2).$$

8) Queremos usar Monte Carlo métodos para aproximar a integral

$$J = \int_X \phi(x) \pi(x) dx$$

Onde $\phi: X \rightarrow \mathbb{R}$ e π é uma densidade de probabilidade em X . Assumimos que temos acesso a uma π densidade de probabilidade proposta π tal que $w(x) = \pi(x)/\phi(x) \leq M < \infty \forall x \in X$.

Considera-se a densidade de probabilidade estendida $\bar{\pi}_{x,0}$ em $X \times [0,1]$ definida como

$$\bar{\pi}_{x,0}(x, u) = \begin{cases} M_g(x) & \text{para } x \in X, u \in [0, \frac{w(x)}{M}] \\ 0 & \text{caso contrário} \end{cases}$$

Verifique que $\bar{\pi}_x(x) = \pi(x)$.

$$\begin{aligned} \bar{\pi}_x(x) &= \int_0^1 \bar{\pi}_{x,0}(x, u) du \\ &= \int_0^{w(x)/M} M_g(x) du \end{aligned}$$

$$= M_g(x) \cdot \left(\frac{w(x)}{M} \right) = \pi(x).$$

⑨ Do problema anterior, usando a identidade

$$I = \int_0^1 \int_X \phi(x) \bar{\pi}_{X,U}(x,u) dx du,$$

de a expressão de estimador de importance sampling \hat{I}_n de I quando usamos n amostras independentes (X_i, U_i) tais que

$(X_i, U_i) \sim \bar{g}$ onde $\bar{g}_{X,U}(x,u) = g(x) \times \mathbb{I}_{[0,1]}(u)$ (ou seja, sobre $\bar{g}_{X,U}$ temos $X \sim g$, $U \sim \text{Unif}[0,1]$ e X e U são independentes). Express este estimador como uma função de peso de importance

$$\bar{w}(x,u) = \frac{\bar{\pi}_{X,U}(x,u)}{\bar{g}_{X,U}(x,u)}.$$

Mostre que este estimador é equivalente ao estimador obtido amostrando π usando rejeição sampling n proporção de g .

A função peso de importance é

$$\bar{w}(x,u) = \begin{cases} 1 & \text{para } x \in X, u \in [0, \frac{w(x)}{m}] \\ 0 & \text{C.C.} \end{cases}$$

Para n amostras $(X_i, U_i) \sim \bar{g}_{X,U}$ temos

$$\hat{I}_n = \frac{\sum_{i=1}^n \phi(X_i) \bar{w}(X_i, U_i)}{\sum_{i=1}^n \bar{w}(X_i, U_i)} = \frac{1}{K} \sum_{i=1}^K \phi(X_{ji})$$

onde X_{j1}, \dots, X_{jk} são amostras com pesos diferentes de zero, ou seja, as amostras distribuídas a partir de π . Portanto, este estimador é equivalente àquela obtida executando um algoritmo de rejeição até amostrarmos n candidatos de g

10) Mostre que

$$\text{Var}_{\bar{q}}(w(x)) \leq \text{Var}_{\bar{q}_{x,u}}(\bar{w}(x,u)).$$

Temos que

$$\text{Var}_{\bar{q}_{x,u}}(\bar{w}(x,u)) = \text{Var}_{\bar{q}_x} \left[E_{\bar{q}_{u|x}} (\bar{w}(x,u)) \right] + E_{\bar{q}_x} \left[\text{Var}_{\bar{q}_{u|x}} (\bar{w}(x,u)) \right]$$

mas

$$\begin{aligned} E_{\bar{q}_{u|x}} (\bar{w}(x,u)) &= E_{\bar{q}_u} (\bar{w}(x,u)) \\ &= \int \bar{w}(x,u) \bar{q}_u(u) du \\ &= w(x) \end{aligned}$$

então

$$\text{Var}_{\bar{q}_{x,u}}(\bar{w}(x,u)) = \text{Var}_{\bar{q}_x}[w(x)] + E_{\bar{q}_x} \left[\underbrace{\text{Var}_{\bar{q}_{u|x}} (\bar{w}(x,u))}_{\geq 0} \right]$$

Assim, daí,

$$\text{Var}_{\bar{q}}(w(x)) \leq \text{Var}_{\bar{q}_{x,u}}(\bar{w}(x,u))$$