

Q) Seja Vamos considerar a densidade da normal multivariada em \mathbb{R}^d com covariância de identidade, ou seja

$$\pi(x) = \frac{1}{(2\pi)^{d/2}} \exp\left\{-\frac{1}{2}x^T x\right\}.$$

(Cameron-Martin formula) Mostre que para qualquer $\theta \in \mathbb{R}^d$ e função $\phi: \mathbb{R}^d \rightarrow \mathbb{R}$

$$\mathbb{E}[\phi(X)] = \mathbb{E}\left[\phi(X+\theta) \exp\left\{-\frac{1}{2}\theta^T \theta - \theta^T x\right\}\right]$$

$$\begin{aligned} \mathbb{E}[\phi(X)] &= \int \phi(x) \frac{1}{(2\pi)^{d/2}} \exp\left\{-\frac{1}{2}x^T x\right\} dx \\ &= \int \phi(y+\theta) \frac{1}{(2\pi)^{d/2}} \exp\left\{-\frac{1}{2}(y+\theta)^T (y+\theta)\right\} dy \\ &= \int \phi(y+\theta) \frac{1}{(2\pi)^{d/2}} \left\{-\frac{1}{2}y^T y\right\} \exp\left\{-\frac{1}{2}\theta^T \theta - \theta^T y\right\} dy \end{aligned}$$

$$= \mathbb{E}\left[\phi(X+\theta) \exp\left\{-\frac{1}{2}\theta^T \theta - \theta^T x\right\}\right]$$



② Do exerçoso anterior. Segue diretamente da formula de Cameron - Martin e da Geisler que, para $X_1, \dots, X_n \sim \mathcal{N}$ independentes, o estimador

$$\hat{I}_n(\theta) = \frac{1}{n} \sum_{i=1}^n \phi(X_i + \theta) \exp\left\{-\frac{1}{2}\theta^T \theta - \theta^T X_i\right\}$$

de $\mathbb{E}(\phi(x))$ é fórmemente consistente para algum $\theta \in \mathbb{R}^d$ tal que $\mathbb{E}[\lvert \phi(X+\theta) \exp\left\{-\frac{1}{2}\theta^T \theta - \theta^T X\right\} \rvert] < \infty$.

O caso $\theta = (0, 0, \dots, 0)^T$ corresponde ao estimador usual de Mala Caso. ③ A variancia de $\hat{I}_n(\theta)$ é dada por $\sigma^2(\theta)/n$ onde

$$\sigma^2(\theta) = \ln\left[\phi(X+\theta) \exp\left\{-\frac{1}{2}\theta^T \theta - \theta^T X\right\}\right].$$

Assumindo que $\sigma^2(\theta)$ é finita para qualquer θ . Mostre que

$$\sigma^2(\theta) = \mathbb{E}\left[\phi^2(X) \exp\left\{-\frac{1}{2}X^T X + \frac{1}{2}(X-\theta)^T(X-\theta)\right\}\right] - (\mathbb{E}[\phi(X)])^2.$$

Temos que

$$\sigma^2(\theta) = \mathbb{E}\left[\phi^2(X+\theta) \exp\left\{-\theta^T \theta - 2\theta^T X\right\}\right] - (\mathbb{E}[\phi(X)])^2.$$

Dai,

$$\mathbb{E}\left[\phi^2(X+\theta) \exp\left\{-\theta^T \theta - 2\theta^T X\right\}\right] =$$

$$= \frac{1}{(2\pi)^{d/2}} \int_X \phi^2(X+\theta) \exp\left\{-\theta^T \theta - 2\theta^T X\right\} \exp\left\{-\frac{1}{2}X^T X\right\} dX$$

$$= \frac{1}{(2\pi)^{d/2}} \int_X \phi^2(z) \exp\left\{-\theta^T \theta - 2\theta^T(z-\theta) - \frac{1}{2}(z-\theta)^T(z-\theta)\right\} dZ$$

$$= \frac{1}{(2\pi)^{d/2}} \int_X \phi^2(z) \exp\left\{-\theta^T \theta - 2\theta^T z + 2\theta^T \theta + \theta^T z - \frac{1}{2}z^T z - \frac{1}{2}\theta^T \theta\right\} dZ$$



$$\begin{aligned} &= \frac{1}{(2\pi)^{d_2}} \int_{\mathbb{R}^{d_2}} \phi^2(z) \exp \left\{ -\frac{1}{2} z^T z - \theta^T z + \frac{1}{2} \theta^T \theta \right\} dz \\ &= \frac{1}{(2\pi)^{d_2}} \int_{\mathbb{R}^{d_2}} \phi^2(z) \exp \left\{ -\frac{1}{2} z^T z \right\} \exp \left\{ \frac{1}{2} \theta^T \theta - \theta^T z \right\} dz \\ &= \mathbb{E} [\phi^2(X) \exp \left\{ \frac{1}{2} \theta^T \theta - \theta^T X \right\}] \\ &= \mathbb{E} [\phi^2(X) \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X - \theta)^T (X - \theta) \right\}] \end{aligned}$$

~~que~~ ~~mostrar~~ que finaliza a prova.



③ Uma função duas vezes diferenciável $f: \mathbb{R}^d \rightarrow \mathbb{R}$ é estilamente convexa se $\nabla^2 f(\theta)$ (a Hessiana de f) é uma matriz positiva definida para todos $\theta \in \mathbb{R}^d$. Dada a expressão de $\nabla^2 \sigma^2(\theta)$ da questão ② e ① que a função $\theta \mapsto \sigma^2(\theta)$ é estilamente convexa

Temos

$$\nabla \sigma^2(\theta) = \nabla \mathbb{E} [\phi^2(X) \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X-\theta)^T (X-\theta) \right\}]$$

$$= \mathbb{E} [\phi^2(X)(\theta-X) \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X-\theta)^T (X-\theta) \right\}]$$

Sendo $H_{ij}(\theta)$ o elemento i,j de $\nabla^2 \sigma^2(\theta)$:

$$H_{ij}(\theta) = [\nabla^2 \sigma^2(\theta)]_{ij} = \frac{\partial^2 \sigma^2(\theta)}{\partial \theta_i \partial \theta_j}$$

$$= \mathbb{E} [\phi^2(X) S_{ij} \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X-\theta)^T (X-\theta) \right\}] +$$

$$+ \mathbb{E} [\phi^2(X)(\theta_i - X_i)(\theta_j - X_j) \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X-\theta)^T (X-\theta) \right\}]$$

onde $S_{ij} = 1$ se $i=j$ e 0 caso contrário. Daí,

$$H(\theta) = \nabla^2 \sigma^2(\theta) = \mathbb{E} [\phi^2(X) \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X-\theta)^T (X-\theta) \right\}] I_d$$

$$+ \mathbb{E} [\phi^2(X)(\theta-X)(\theta-X)^T \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X-\theta)^T (X-\theta) \right\}]$$

Para qualquer vetor não-nulo $u \in \mathbb{R}^d$:

$$u^T H(\theta) u = \mathbb{E} [\phi^2(X) \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X-\theta)^T (X-\theta) \right\}] [\|u\|^2 + (u^T (X-\theta))^2]$$

Como $\|u\|^2 > 0$ e $(u^T (X-\theta))^2 \geq 0$, $u^T H(\theta) u > 0$. Logo $H(\theta)$ é definida.

(4) Considerando os exercícios anteriores. Mostre que o mínimo de $\theta \mapsto \sigma^2(\theta)$ é atingido com θ^* tal que

$$\mathbb{E}[\phi^2(x)(\theta^* - x)\exp(-\theta^{*T}x)] = 0.$$

Temos que

$$\begin{aligned}\nabla \sigma^2(\theta) &= \mathbb{E}[\phi^2(x)(\theta - x)\exp\left\{-\frac{1}{2}x^T x + \frac{1}{2}(x - \theta)^T(x - \theta)\right\}] \\ &= \mathbb{E}[\phi^2(x)(\cancel{\theta} - \theta - x)\exp\left\{\frac{1}{2}\theta^T\theta - \theta^Tx\right\}] \\ &= \underbrace{\exp\left\{\frac{1}{2}\theta^T\theta\right\}}_{>0} \mathbb{E}[\phi^2(x)(\theta - x)\exp\{-\theta^Tx\}]\end{aligned}$$

Logo, $\nabla \sigma^2(\theta) = 0$ se e só se $\mathbb{E}[\phi^2(x)(\theta - x)\exp\{-\theta^Tx\}] = 0$.
Por ser convexa é o que minimiza $\theta \mapsto \sigma^2(\theta)$.

5 Aplicamos os resultados anteriores a um modelo de opções europeas no modelo Black-Scholes. Queremos computar

$$I = \exp\{-rT\} \mathbb{E}[\max\{0, \lambda \exp\{\theta X\} - k\}]$$

Onde $X \sim N(0,1)$ e r, λ, k, θ, T são constantes reais positivas com $\lambda < k$. Note que $\theta \rightarrow \sigma^2(\theta)$ é decrescente em $D = (-\infty, \sigma^{-1} \log(k/\lambda))$. Deduza deste resultado que existe um intervalo de valores de θ tal que a variancia de $\hat{I}_n(\theta)$ é estatisticamente menor que a variancia do usual estimador Monte Carlo.

Estamos interessados em $I = \exp\{-rT\} \mathbb{E}[\phi(X)]$, onde $\phi(x) = \max\{0, \lambda \exp\{\theta x\} - k\}$. Queremos mostrar que a derivada de $\sigma^2(\theta)$ é negativa, ou seja, mostrar que

$$\nabla \sigma^2(\theta) = \exp\left(\frac{1}{2}\theta^2\right) \mathbb{E}[\phi'(x)(\theta - x) \exp(-\theta x)] \leq 0.$$

$$\Leftrightarrow \theta \mathbb{E}[\phi'(x) \exp\{\theta - \theta x\}] - \mathbb{E}[\phi'(x)x \exp\{-\theta x\}] \leq 0.$$

$$\Leftrightarrow \theta \mathbb{E}[(\lambda \exp\{\theta x\} - k)^2 \exp\{-\theta x\}] \mathbb{E}_{D^c}(X)$$

$$- \mathbb{E}[(\lambda \exp\{\theta x\} - k)^2 X \exp\{-\theta x\}] \mathbb{E}_{D^c}(X) \leq 0.$$

- Caso $\theta < 0$, temos que a primeira esperança é positiva e a segunda é maior igual a zero, logo vale.
- Caso $\theta \in (0, \sigma^{-1} \log(k/\lambda))$, então $\theta \leq x \Rightarrow$ (caso contrário temos $X \in D$), dai $(\theta - x) \leq 0 \Rightarrow \nabla \sigma^2(\theta) \leq 0$. Para $\theta = 0$ temos o usual estimador de Monte Carlo, como a variancia de $\hat{I}_n(\theta)$ é decrescente em $(0, \sigma^{-1} \log(k/\lambda))$, então é um estimador tilibra melhor.



⑥ Seja X um espaço de estados finitos. Considere o seguinte Kernel de Transição Markov.

$$T(x,y) = \alpha(x,y)g(x,y) + \left(1 - \sum_{z \in X} \alpha(x,z)g(x,z)\right)S_x(y)$$

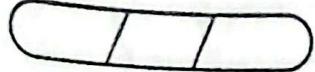
onde $g(x,y) \geq 0$, $\sum_{y \in X} g(x,y) = 1$ e $0 \leq \alpha(x,y) \leq 1$, $\forall x, y \in X$. $S_x(y)$ é o símbolo Kronecker, ou seja, $S_x(y) = 1$ se $y = x$ e 0 caso contrário.

Explique como você simulaia uma cadeia de Markov com o Kernel de Transição T .

O algoritmo no parágrafo dado por:

- $X_t \sim g(X_{t-1}, \cdot)$
- $U \sim \text{Unif}[0,1]$
- Se $U \leq \alpha(X_{t-1}, x)$, então $X_t = x$
caso contrário tomamos $X_t = X_{t-1}$.

O termo $(1 - \sum_{z \in X} \alpha(x,z)g(x,z))$ explica a probabilidade de permanecer no estado atual. T é um Kernel de Transição válido que garante que a cadeia de Markov respeita as propriedades de uma distribuição de probabilidade.



17) Seja π uma função de massa de probabilidade em X . Mostre que se

$$\alpha(x,y) = \frac{\gamma(x,y)}{\pi(x)g(x,y)}$$

onde $\gamma(x,y) = \gamma(y,x)$ e $\gamma(x,y)$ é escalar tal que $0 \leq \alpha(x,y) \leq 1$ $\forall x, y \in X$ então T é reversível sobre π .

Para $x=y$, vale, basta mostrar que

$$\pi(x)T(x,y) = \pi(y)T(y,x), \quad \forall x, y \in X, x \neq y$$

$$\Leftrightarrow \pi(x)g(x,y)\alpha(x,y) = \pi(y)g(y,x)\alpha(y,x)$$

$$\Leftrightarrow \frac{\pi(x)g(x,y)}{\pi(x)g(x,y)} \frac{\gamma(x,y)}{\gamma(y,x)} = \frac{\pi(y)g(y,x)}{\pi(y)g(y,x)} \frac{\gamma(y,x)}{\gamma(x,y)}$$

$$\Leftrightarrow \gamma(x,y) = \gamma(y,x)$$

8) Mostre que o algoritmo de Metropolis-Hastings converge a uma escolha particular de $\gamma(x, y)$.

Como

$$\alpha(x, y) = \min \left\{ 1, \frac{\pi(y) g(y, x)}{\pi(x) g(x, y)} \right\}$$

E queremos

$$\frac{\gamma(x, y)}{\pi(x) g(x, y)} = \min \left\{ 1, \frac{\pi(y) g(y, x)}{\pi(x) g(x, y)} \right\},$$

basta tomar $\gamma(x, y) = \min \{ \pi(y) g(y, x), \pi(x) g(x, y) \}$ preservando a reflexividade.

9) Seja π uma função de massa de probabilidade num espaço finito X tal que $\pi(x) > 0, \forall x \in X$. Para amostrar de π , rodamos um Metropolis-Hastings $(X_t)_{t \geq 0}$ com proposta $g(x,y) \geq 0$, tal que $\sum_{y \in X} g(x,y) = 1$ e $g(x,x) = 0 \quad \forall x \in X$. Considere aqui a sequência $(Y_k)_{k \geq 1}$ de propostas aceitas. $Y_1 = X_{(\tau_1)}$ onde $\tau_1 = 1$ e para $k \geq 2$, $Y_{(k)} = X_{(\tau_k)}$ onde $\tau_k = \min\{t : t > \tau_{k-1}, X_{(t)} \neq Y_{(t-1)}\}$

Seja $\phi : X \rightarrow \mathbb{R}$ uma função teste. Mostre que o estimador $\frac{1}{\tau_k - 1} \sum_{t=1}^{\tau_k - 1} \phi(X_{(t)})$ pode ser escrito como uma função de $(Y_k)_{k \geq 1}$ e $(\tau_k)_{k \geq 1}$ e prove que a sequência $(Y_k)_{k \geq 1}$ é uma cadeia de Markov com Kernel de transição

$$K(x,y) = \frac{\alpha(x,y) g(x,y)}{\sum_{z \in X} \alpha(x,z) g(x,z)}$$

Para a primeira parte temos que

$$\frac{1}{\tau_k - 1} \sum_{t=1}^{\tau_k - 1} \phi(X_{(t)}) = \frac{1}{\tau_k - 1} \sum_{j=1}^{\tau_k - 1} \phi(Y_{(j)}) (Y_{(j+1)} - Y_j)$$

Agora para a segunda parte, $Y_{(k)}$ é aceito então

$$P(Y_{(k)} = y | Y_1, \dots, Y_{(k-1)} = x) = P(X_{(\tau_k)} = y | X_{(\tau_1)}, \dots, X_{(\tau_{k-1})} = x)$$

$$= P(X_{(\tau_k)} = y | X_{(\tau_{k-1})} = x)$$

$$= \frac{\alpha(x,y) g(x,y)}{\sum_{z \in X} \alpha(x,z) g(x,z)}$$

(10) Mostre que o Kernel de transição $K(x,y)$ da cadeia de Markov $(Y_{(n)})_{n \geq 1}$ é $\tilde{\pi}$ -reversível onde

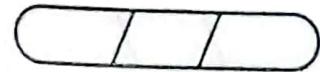
$$\tilde{\pi}(x) = \frac{\pi(x)m(x)}{\sum_{z \in X} \pi(z)m(z)}$$

com

$$m(x) := \sum_{z \in X} \alpha(x,z) q(x,z)$$

Temos que

$$\begin{aligned} \tilde{\pi}(x) K(x,y) &= \frac{\pi(x)m(x)}{\sum_{z \in X} \pi(z)m(z)} \cdot \frac{\alpha(x,y) q(x,y)}{\sum_{z \in X} \alpha(x,z) q(x,z)} \\ &= \frac{\pi(x)m(x)}{\sum_z m(x)} \cdot \frac{\alpha(x,y) q(x,y)}{\sum_z m(x)} \\ &= \frac{1}{\sum_z \alpha(x,y) q(x,y)} \cdot \frac{\alpha(x,y) q(x,y)}{\sum_z \alpha(x,z) q(x,z)} \\ &= \frac{\pi(y,x)}{\sum_z \alpha(y,x) q(y,z)} \\ &= \frac{1}{\sum_z \alpha(y,x) q(y,z)} \cdot \alpha(y,x) q(y,x) \\ &= \frac{\pi(y)m(y)}{\sum_z \pi(z)m(z)} \cdot \frac{\alpha(y,x) q(y,x)}{\sum_z \alpha(y,z) q(y,z)} \\ &= \frac{\pi(y)m(y)}{\sum_{z \in X} \pi(z)m(z)} \cdot \frac{\alpha(y,x) q(y,x)}{\sum_{z \in X} \alpha(y,z) q(y,z)} = \tilde{\pi}(y) K(y,x). \end{aligned}$$



II) Assuma que para algum teste $\phi: \mathbb{X} \rightarrow \mathbb{R}$ temos que

$$\frac{1}{k} \sum_{i=1}^k \phi(Y_{(i)}) \xrightarrow{\text{q.c.}} \sum_{x \in \mathbb{X}} \phi(x) \tilde{\pi}(x)$$

e assuma que $m(x)$ pode ser computado exatamente $\forall x \in \mathbb{X}$.
Proponha um estimador faltamente consistente de $\sum_{x \in \mathbb{X}} \phi(x) \pi(x)$ baseado na cadeia de Markov $(Y_{(n)})_{n \geq 1}$ a qual depende de $(\tau_n)_{n \geq 1}$.

Temos que

$$\begin{aligned} \sum_{x \in \mathbb{X}} \phi(x) \tilde{\pi}(x) &= \frac{\sum_{x \in \mathbb{X}} \phi(x) \tilde{\pi}(x)}{\sum_{x \in \mathbb{X}} \tilde{\pi}(x)} \\ &= \frac{\sum_{x \in \mathbb{X}} \phi(x) \frac{\tilde{\pi}(x)}{\tilde{\pi}(x)} \tilde{\pi}(x)}{\sum_{x \in \mathbb{X}} \frac{\tilde{\pi}(x)}{\tilde{\pi}(x)} \tilde{\pi}(x)} \end{aligned}$$

como $\frac{\tilde{\pi}(x)}{\tilde{\pi}(x)} \propto \frac{1}{m(x)}$. Um estimador faltamente consistente é

$$\frac{\sum \phi(Y_{(n)}) / m(Y_{(n)})}{\sum 1 / m(Y_{(n)})}$$